

# Numerical Analysis

## Exam Minimum

Astral Projection

2026 年 1 月 10 日



# 目录

一 数学基础知识	7
(一) 核心概念与理论	7
1. 线性空间	7
2. 度量与赋范空间	8
3. 内积空间	11
4. 正交多项式	12
5. 矩阵分析回顾	15
6. 矩阵空间	16
二 函数插值与重构	19
(一) 通用理论	20
1. 问题模型	20
2. 插值空间	20
3. 误差分析与收敛性	20
(二) 具体插值方法	20
1. 一维多项式插值	20
2. 分段插值	25
3. Fourier 插值	26
三 函数逼近	29
(一) 通用理论	30
1. 问题模型	30
2. 逼近准则	30
3. 核心定理	30
(二) 具体逼近方法	30
1. 最优平方逼近	30
2. 最小二乘逼近: 最优平方逼近的离散化形式	33
3. 最佳一直逼近	34

四 数值微积分	37
(一) 数值积分	38
1. 通用理论	38
2. 具体求积方法	38
(二) 数值微分	38
1. 基础方法	38
2. 高精度方法	38
五 非线性方程求根	39
(一) 通用理论	40
1. 问题模型	40
2. 迭代法基础	40
3. 收敛性分析	40
4. 收敛效率	40
(二) 具体方法	40
1. 单步法	40
2. 多步法	40
3. 其他方法	40
六 常微分方程初值问题数值解法	41
(一) 通用理论	42
1. 问题模型	42
2. 数值解法核心	42
3. 基本概念	42
4. 收敛性与稳定性判定	42
(二) 具体方法	42
1. 单步法	42
2. 多步法	42
七 线性代数方程组数值解法	43
(一) 线性代数方程组直接解法 (Direct Methods)	43
1. 基本概念	43
2. Gauss 消去法 (Gauss Elimination)	43
3. 矩阵三角分解 (Matrix Factorization)	44
4. 误差分析与条件数	46
5. 广义逆与正则化 (Generalized Inverse & Regularization)	48
(二) 单步定常线性迭代解法 (Stationary Linear Iterative Methods)	49
1. 迭代法基础理论	49
2. 经典迭代方法	51

(三) 非定常迭代法 (Krylov Subspace Methods) . . . . .	53
1. 变分原理与 Ritz 方法基础 . . . . .	53
2. 最速下降法 (Steepest Descent) . . . . .	55
3. 共轭梯度法 (Conjugate Gradient, CG) . . . . .	57
4. 预处理技术 (Preconditioning) . . . . .	57



# 一 数学基础知识

## (一) 核心概念与理论

### 1. 线性空间

#### (1) 定义与性质

**定义 (线性空间).** 设  $S$  是一个集合,  $P$  是一个数域 ( $\mathbb{R}$  或  $\mathbb{C}$ ). 定义两种映射关系:

- 向量加法:  $+: S \times S \rightarrow S$
- 数乘:  $\cdot: P \times S \rightarrow S$

如果对任意的  $u, v, w \in S$  和  $a, b \in P$ , 满足以下八条公理, 则称  $(S, P)$  为一个线性空间 (向量空间):

1. 加法交换律:  $u + v = v + u$
2. 加法结合律:  $(u + v) + w = u + (v + w)$
3. 存在加法单位元: 存在零向量  $0 \in S$ , 使得对任意  $v \in S$ , 有  $v + 0 = v$
4. 存在加法逆元: 对任意  $v \in S$ , 存在  $-v \in S$ , 使得  $v + (-v) = 0$
5. 数乘结合律:  $a(bv) = (ab)v$
6. 数乘分配律 1:  $a(u + v) = au + av$
7. 数乘分配律 2:  $(a + b)v = av + bv$
8. 数乘单位元:  $1v = v$

则称  $(S, P)$  构成一个线性空间。

此外, 如果对于给定空间的运算法则和数域是不言自明的, 则通常简写为  $S$  是一个线性空间。如我们说  $\mathbb{R}^n$  是一个线性空间, 通常指  $(\mathbb{R}^n, \mathbb{R})$  是一个线性空间或  $(\mathbb{R}^n, \mathbb{C})$  是一个线性空间, 具体取决于数域的选择。

## (2) 线性无关与相关

待填写: (定义) 线性无关与线性相关

## (3) 基、框架与维数

待填写: (定义) 基、框架与维数

性质:

- 空间的维度是一个内蕴量, 与基的选择无关
- 多项式空间  $P_N$  中,  $\{1, x, x^2, \dots, x^N\}$  构成其一组基, 维数为  $\dim P_N = N + 1$
- 连续函数空间  $C[a, b]$  中,  $\forall N, \{1, x, x^2, \dots, x^N\}$  是线性无关的, 但不能构成其基, 因其维数为无穷大

## 2. 度量与赋范空间

### (1) 距离空间

**定义** (距离空间). 设  $M$  是一个集合,  $d: M \times M \rightarrow \mathbb{R}$  是一个映射, 如果对任意的  $x, y, z \in M$ , 满足以下三条公理, 则称  $(M, d)$  为一个距离空间:

1. 非负性与分离性:  $d(x, y) \geq 0$ , 且当且仅当  $x = y$  时,  $d(x, y) = 0$
2. 对称性:  $d(x, y) = d(y, x)$
3. 三角不等式:  $d(x, z) \leq d(x, y) + d(y, z)$

则称  $(M, d)$  构成一个距离空间。

### (2) 距离空间的完备性

待填写: (定义) 完备性

$\mathbb{R}$  是完备的, 且任意有限维赋范空间都是完备的。

#### a. 构造方法: 距离空间的完备化

设  $(M, d)$  是一个距离空间, 可以按照如下过程构造其完备化空间:

1. 构造对偶的柯西列空间

$$\tilde{M} = \{(x_n) \mid x_n \in M, (x_n) \text{ 为柯西列}\}$$



2. 在柯西列空间  $\tilde{M}$  中定义等价关系

$$\tilde{x} \sim \tilde{y} \leftrightarrow \lim_{n \rightarrow \infty} d(x_n, y_n) = 0$$

即这两个柯西列按照角标顺序，交叉放在一起，还是柯西列。

3. 构造商空间：

$$\hat{M} = \tilde{M} / \sim = \{[\tilde{x}]\}$$

式中， $[\tilde{x}]$  表示柯西列  $\tilde{x}$  的等价类，即  $[\tilde{x}]$  是一个集合，集合中的所有元素在等价关系  $\sim$  下都是等价的。

4. 在商空间  $\hat{M}$  中定义距离

$$\hat{d}([\tilde{x}], [\tilde{y}]) = \lim_{n \rightarrow \infty} d(x_n, y_n)$$

5. 则  $(\hat{M}, \hat{d})$  即为距离空间  $(M, d)$  的完备化空间。

嵌入映射：可以在原空间  $M$  与完备化空间  $\hat{M}$  之间定义一个单射  $i$ ：

$$i : M \rightarrow \hat{M}, \quad i(x) = [(x, x, x, \dots)]$$

该映射将原空间中的每个点  $x$  映射为完备化空间中由常值序列  $(x, x, x, \dots)$  所构成的等价类，且映射前后任意两元素的距离不变

### (3) 赋范空间与 Banach 空间

**待填写：(定义) 赋范空间**

完备的赋范空间称为 Banach 空间，或者 B 空间。

### (4) 等价范数

**定义** (范数的等价性). 设  $V$  是一个线性空间， $\|\cdot\|_1$  和  $\|\cdot\|_2$  是  $V$  上的两个范数，如果存在正常数  $c$  和  $C$ ，使得对任意  $v \in V$ ，都有

$$c\|v\|_1 \leq \|v\|_2 \leq C\|v\|_1$$

则称这两个范数是等价的。

若存在正数  $C$ ，使得对任意  $v \in V$ ，都有

$$\|v\|_2 \leq C\|v\|_1$$

则称范数  $\|\cdot\|_1$  强于  $\|\cdot\|_2$ 。

性质：

- 在有限维线性空间上，任意两个范数都是等价的
- 在无限维线性空间上，范数不一定是等价的
- 若一个点列在较强的范数下是 Cauchy 列，则在较弱的范数下也是 Cauchy 列；反之不必然。

## (5) 常用的范数

### a. $\mathbb{R}^n$ 上的范数

记  $x = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$ , 则常用的范数有:

- 无穷范数: 所有元素的最大值

$$\|x\|_{\infty} = \max_{1 \leq i \leq n} |x_i|$$

- 1-范数: 所有元素的绝对值之和

$$\|x\|_1 = \sum_{i=1}^n |x_i|$$

- 2-范数: 欧几里得范数, 即所有元素的平方和的平方根

$$\|x\|_2 = \left( \sum_{i=1}^n |x_i|^2 \right)^{\frac{1}{2}}$$

### b. $C[a, b]$ (有界闭区间上连续函数空间) 上的范数

- 无穷范数: 函数在区间上的最大绝对值

$$\|f\|_{\infty} = \max_{a \leq x \leq b} |f(x)|$$

- 1-范数: 函数在区间上的绝对值积分

$$\|f\|_1 = \int_a^b |f(x)| dx$$

- 2-范数: 函数在区间上的平方积分的平方根

$$\|f\|_2 = \left( \int_a^b |f(x)|^2 dx \right)^{\frac{1}{2}}$$

$C[a, b]$  上三个范数的性质:

- 任意两个范数不等价
- 无穷范数强于 2 范数, 2 范数强于 1 范数
- 只有无穷范数对应的赋范空间是完备的
- 1-范数对应的完备化空间为  $L^1(a, b)$ , 2-范数对应的完备化空间为  $L^2(a, b)$ <sup>1</sup>

---

<sup>1</sup> $L^1(a, b)$  为  $(a, b)$  上的可积函数空间,  $L^2(a, b)$  为  $(a, b)$  上的平方可积函数空间。

### 3. 内积空间

#### (1) 内积定义与性质

**定义 (内积).** 设  $(S, P)$  是一个线性空间, 如果对任意的  $u, v, w \in S$  和  $a, b \in P$ , 存在一个映射  $S \times S \rightarrow P$ , 满足

1. 共轭对称性:  $\langle u, v \rangle = \overline{\langle v, u \rangle}$
2. 线性性:  $\langle au + bv, w \rangle = a\langle u, w \rangle + b\langle v, w \rangle$
3. 正定性:  $\langle v, v \rangle \geq 0$ , 且当且仅当  $v = 0$  时,  $\langle v, v \rangle = 0$

则称该映射为内积,  $(S, P)$  构成一个内积空间。

若  $\langle x, y \rangle = 0$ , 则称  $x$  与  $y$  正交。

几个常用空间上的内积:

- $\mathbb{R}^n$  或  $\mathbb{C}^n$  上的内积

$$\langle x, y \rangle = \sum_{i=1}^n x_i \overline{y_i}$$

- $C[a, b]$  (有界闭区间上连续函数空间) 上的内积

$$\langle f, g \rangle = \int_a^b f(x) \overline{g(x)} dx$$

- $C[a, b]$  上的带权内积:

$$(f, g) = \int_a^b \rho(x) f(x) \overline{g(x)} dx$$

其中, 权函数  $\rho(x)$  需要满足条件:

- $\rho(x) \in C[a, b]$
- $\rho(x)$  几乎处处为正
- $\int_a^b \rho(x) dx < +\infty$
- $\forall q(x) \in P_n, \int_a^b \rho(x) |q(x)| dx < \infty$

带权内积所研究的空间称为加权内积空间:

$$L_\rho^2(a, b) = \{f(x) \mid \int_a^b \rho(x) |f(x)|^2 dx < +\infty\}$$

常用的权函数有:

$$\begin{aligned} \rho(x) &= 1, \quad [a, b] = [-1, 1] \\ \rho(x) &= \frac{1}{1-x^2}, \quad [a, b] = [-1, 1] \end{aligned}$$

## (2) 正交性与 Schmidt 正交化

待填写: (定义) 正交性

待填写: (方法) 用 *Grammer* 矩阵判断内积空间中向量组的线性无关性

待填写: (方法) *Schmidt* 正交化过程: 从一个线性无关向量组构造一个正交向量组: 让每个向量减去与已有空间垂直的分量

用 Schmidt 正交化过程得到的正交向量组具有以下性质:

$$\Phi_{k-1} \subset \Phi_k$$

$$y_k \perp \Phi_{k-1}$$

## (3) 由内积诱导的范数

定义 (诱导范数). 设  $(S, P)$  是一个内积空间, 则可以定义范数  $\|\cdot\|$  如下:

$$\|v\| = \sqrt{\langle v, v \rangle}$$

则称该范数为由内积诱导的范数。

- 任何内积均能诱导对应的范数
- 当且仅当范数满足平行四边形法则时

$$\|f + g\|^2 + \|f - g\|^2 = 2\|f\|^2 + 2\|g\|^2$$

范数可以诱导内积:

$$(x, y) = \frac{1}{4}(\|x + y\|^2 - \|x - y\|^2 + i\|x + iy\|^2 - i\|x - iy\|^2)$$

## 4. 正交多项式

定义 (正交多项式). 设  $\{\phi_n(x)\}$  是定义在区间  $[a, b]$  上的一组多项式, 且每个多项式的次数为  $n$ , 如果对任意  $m \neq n$ , 都有

$$\int_a^b \rho(x) \phi_m(x) \phi_n(x) dx = 0$$

则称  $\{\phi_n(x)\}$  为区间  $[a, b]$  上关于权函数  $\rho(x)$  的正交多项式。

正交多项式的性质:

- $\deg \phi_i = i$
- $(\phi_i, \phi_j) = 0, \quad \forall i \neq j$
- $\phi_n$  为实系数多项式
- $\phi_n$  在开区间  $(a, b)$  内恰有  $n$  个实单根

待填写: (证明)  $\phi_n$  在开区间  $(a, b)$  内恰有  $n$  个实单根的证明。证法: 分别证明实根、单根、全在  $(a, b)$  内。3 个命题均可用反证法。

**(1)  $\rho = 1$ : Legendre 多项式**

产生方法:

- 权函数  $\rho(x) = 1$
- 区间  $[-1, 1]$

表达式:

$$P_n(x) = \frac{1}{2^n n!} \frac{d^n}{dx^n} [(x^2 - 1)^n]$$

性质:

- 首项系数:

$$k_n = \frac{(2n)!}{2^n (n!)^2}$$

- 正交归一化:

$$\int_{-1}^1 P_n(x) P_m(x) dx = \frac{2}{2n+1} \delta_{mn}$$

- 三项递推关系:

$$(n+1)P_{n+1}(x) = (2n+1)xP_n(x) - nP_{n-1}(x)$$

- 奇偶性:

$$P_n(-x) = (-1)^n P_n(x)$$

- 导数关系:

$$\frac{d}{dx} P_n(x) = \frac{n}{x^2 - 1} [xP_n(x) - P_{n-1}(x)]$$

- 前五项:

$$P_0(x) = 1$$

$$P_1(x) = x$$

$$P_2(x) = \frac{1}{2}(3x^2 - 1)$$

$$P_3(x) = \frac{1}{2}(5x^3 - 3x)$$

$$P_4(x) = \frac{1}{8}(35x^4 - 30x^2 + 3)$$

- 零平方误差最小:

**定理.** 在所有首项为 1 的  $n$  次多项式中, Legendre 多项式  $\tilde{P}_n(x)$  在  $[-1, 1]$  上与零的平方误差最小。

**(2)  $\rho(x) = \frac{1}{\sqrt{1-x^2}}$ : Chebyshev 多项式**

产生方法:

- 权函数  $\rho(x) = \frac{1}{\sqrt{1-x^2}}$
- 区间  $[-1, 1]$

表达式:

$$T_n(x) = \cos(n \arccos x)$$

性质:

- 首项系数:  $2^{n-1}$
- 正交归一化:

$$\int_{-1}^1 \frac{T_n(x)T_m(x)}{\sqrt{1-x^2}} dx = \begin{cases} \pi, & n = m = 0 \\ \frac{\pi}{2}, & n = m \neq 0 \\ 0, & n \neq m \end{cases}$$

- 三项递推关系:

$$T_{n+1} = 2xT_n - T_{n-1}$$

- 奇偶性:

$$T_n(-x) = (-1)^n T_n(x)$$

- 前五项:

$$T_0(x) = 1$$

$$T_1(x) = x$$

$$T_2(x) = 2x^2 - 1$$

$$T_3(x) = 4x^3 - 3x$$

$$T_4(x) = 8x^4 - 8x^2 + 1$$

- 零点:

$$x_k = \cos\left(\frac{2k-1}{2n}\pi\right), \quad k = 1, 2, \dots, n$$

- 极值点:

$$x_k = \cos\left(\frac{k\pi}{n}\right), \quad k = 0, 1, \dots, n$$

- 简单表达式: 当  $|x| \geq 1$  时,

$$T_n(x) = \frac{1}{2} \left[ \left( x + \sqrt{x^2 - 1} \right)^n + \left( x - \sqrt{x^2 - 1} \right)^n \right]$$

## 5. 矩阵分析回顾

### (1) 矩阵代数与初等变换 (Elementary Transformations)

**初等矩阵**: 由单位矩阵  $I$  经过一次初等变换得到的矩阵。

1. **交换矩阵 (Permutation Matrix)  $P_{ij}$** : 交换  $I$  的第  $i$  行和第  $j$  行。

- 作用: 左乘交换矩阵的行, 右乘交换矩阵的列。
- 性质:  $P_{ij}^{-1} = P_{ij}^T = P_{ij}$  (对称且正交)。
- 应用: Gauss 消去法中的选主元 ( $PA = LU$ )。

2. **倍乘矩阵 (Scaling Matrix)  $D_i(k)$** : 将  $I$  的第  $i$  行乘以非零常数  $k$ 。

- 性质:  $D_i(k)$  是对角阵。  $D_i(k)^{-1} = D_i(1/k)$ 。

3. **倍加矩阵 (Elimination/Shear Matrix)  $E_{ij}(k)$  ( $i \neq j$ )**: 将  $I$  的第  $j$  行的  $k$  倍加到第  $i$  行。

$$E_{ij}(k) = I + ke_i e_j^T$$

- 作用: 左乘  $A$  将第  $j$  行的  $k$  倍加到第  $i$  行 (消元操作)。
- 性质: 1. 逆矩阵形式简单:  $(E_{ij}(k))^{-1} = E_{ij}(-k)$ 。 2. Gauss 消去法中的消元矩阵  $L_k$  就是一系列倍加矩阵的乘积。

### (2) 矩阵特征值理论

- **特征分解**:  $Ax = \lambda x$ 。
- **SVD 分解**:  $A = U\Sigma V^H$ 。
- **Schur 分解**:  $U^H A U = T$ 。

### (3) 特殊矩阵类

- **Hermite 矩阵 (实对称矩阵)**:  $A^H = A$ 。
  - 特征值全为实数。
  - 存在酉矩阵  $U$  使得  $U^H A U = \Lambda$  (可酉对角化)。
  - **Rayleigh 商**:  $\lambda_{\min} \leq \frac{x^H A x}{x^H x} \leq \lambda_{\max}$ 。
- **对称正定矩阵 (Symmetric Positive Definite, SPD)**:

**定义** (SPD 定义). 实对称矩阵  $A$  称为正定的, 如果对任意非零向量  $x \in \mathbb{R}^n, x \neq 0$ , 都有:

$$x^T A x > 0$$

这定义了一个**能量范数** (Energy Norm):  $\|x\|_A = \sqrt{x^T A x}$ 。

性质:

1. **特征值**: 所有特征值均严格大于 0 ( $\lambda_i > 0$ )。
  2. **行列式**:  $\det(A) = \prod \lambda_i > 0$ , 故  $A$  必可逆。
  3. **主子式**: 所有顺序主子式均大于 0 (Sylvester 准则)。
  4. **对角元**:  $a_{ii} > 0$ , 且  $\max_{i,j} |a_{ij}| = \max_i a_{ii}$  (最大元素必在对角线上)。
  5. **逆矩阵**: 若  $A$  是 SPD, 则  $A^{-1}$  也是 SPD。
  6. **Cholesky 分解**:  $A$  存在唯一的分解  $A = LL^T$ , 其中  $L$  为对角元为正的下三角阵。
- **酉矩阵 (正交矩阵)**:  $U^H U = I$ 。保持向量 2-范数不变 ( $\|Ux\|_2 = \|x\|_2$ )。

## 6. 矩阵空间

**待填写: (性质) 矩阵空间的基本性质: 线性空间、乘法运算、代数性质**

### (1) 矩阵范数

**定义 (矩阵范数)**. 矩阵空间  $\mathbb{C}^{n \times n}$  上的范数  $\|\cdot\|$  称为矩阵范数, 如果对任意的  $A, B \in \mathbb{C}^{n \times n}$  和  $a \in \mathbb{C}$ , 满足以下性质:

1. 非负性与分离性:  $\|A\| \geq 0$ , 且当且仅当  $A = 0$  时,  $\|A\| = 0$
2. 齐次性:  $\|aA\| = |a|\|A\|$
3. 三角不等式:  $\|A + B\| \leq \|A\| + \|B\|$
4. 次乘性:  $\|AB\| \leq \|A\| \cdot \|B\|$

Note: 矩阵范数是定义在矩阵代数而非矩阵空间上的, 必须与矩阵乘法相容。

**定义 (矩阵范数与向量范数的相容性)**. 设  $\|\cdot\|_v$  是向量空间  $\mathbb{C}^n$  上的一个范数,  $\|\cdot\|_m$  是矩阵空间  $\mathbb{C}^{n \times n}$  上的一个范数, 如果对任意的  $A \in \mathbb{C}^{n \times n}$  和  $x \in \mathbb{C}^n$ , 都有

$$\|Ax\|_v \leq \|A\|_m \cdot \|x\|_v$$

则称矩阵范数  $\|\cdot\|_m$  与向量范数  $\|\cdot\|_v$  是相容的。

矩阵范数的两种常见构造方法:

- 直接构造: Frobenius 范数

$$\|A\|_F = \left( \sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 \right)^{\frac{1}{2}}$$

Frobenius 范数的性质:



- Frobenius 范数与向量 2-范数相容
- $\|I\|_F = \sqrt{n}$

- 向量范数诱导：算子范数

**定义** (算子范数). 设  $\|\cdot\|_v$  是向量空间  $\mathbb{C}^n$  上的一个范数, 则可以定义矩阵空间  $\mathbb{C}^{n \times n}$  上的算子范数  $\|\cdot\|_m$  如下:

$$\|A\|_m = \max_{x \neq 0} \frac{\|Ax\|_v}{\|x\|_v} = \max_{\|x\|_v=1} \|Ax\|_v$$

则称该范数为由向量范数  $\|\cdot\|_v$  诱导的算子范数。

常用的几个算子范数:

- 无穷范数: 行和最大值

$$\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

- 1-范数: 列和最大值

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$$

- 2-范数 (谱范数):  $A$  的最大奇异值, 即  $A^H A$  的最大特征值的平方根

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^H A)}$$

## (2) 谱半径

**定义** (谱半径). 谱半径定义为矩阵所有特征值模的最大值, 即

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|$$

谱半径和矩阵范数的关系:

- 矩阵范数下界:

**定理.** 对任意  $A \in \mathbb{C}^{n \times n}$ , 有

$$\rho(A) \leq \|A\|$$

- 无穷接近范数的存在性:

**定理.** 对任意  $A \in \mathbb{C}^{n \times n}$ , 存在一个矩阵范数  $\|\cdot\|$ , 使得

$$\rho(A) \leq \|A\| \leq \rho(A) + \varepsilon$$

其中,  $\varepsilon$  为任意给定的正常数。

### (3) 可逆矩阵相关定理

**定理 (扰动引理 I).** 给定  $B \in \mathbb{C}^{n \times n}$ 。设  $\|B\| < 1$ ，则  $I + B$  可逆，且

$$\|(I + B)^{-1}\| \leq \frac{1}{1 - \|B\|}$$

**定理 (扰动引理 II).** 设  $A, C \in \mathbb{C}^{n \times n}$ ，且  $A$  可逆。若

$$\|C - A\| < \frac{1}{\|A^{-1}\|}$$

则  $C$  也可逆，且

$$\|C^{-1}\| \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\| \cdot \|C - A\|}$$

**定理 (扰动定理 II).** 设  $A, \delta A \in \mathbb{C}^{n \times n}$ ，且  $A$  可逆。若  $\|A^{-1}\delta A\| < 1$ ，则  $A + \delta A$  也可逆，且

$$\|(A + \delta A)^{-1}\| \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\| \cdot \|\delta A\|}$$

## 二 函数插值与重构

**总结：基本方法是利用插值基函数构造插值多项式，从而实现对函数的近似与重构。**

问题 1：求解插值函数

- 整个区间上的连续插值：Lagrange 插值、Newton 插值、Hermite 插值

– Lagrange 插值基函数：

$$L_{\alpha}(x) = \prod_{\substack{\beta \in I \\ \beta \neq \alpha}} \frac{x - x_{\beta}}{x_{\alpha} - x_{\beta}}, \quad \alpha \in I$$

– Newton 插值和 Hermite 插值：构造均差表，列表计算。

\* 均差递推关系：

$$\begin{aligned} f[x_i] &= f(x_i) \\ f[x_i, x_{i+1}, \dots, x_{i+k}] &= \frac{f[x_{i+1}, \dots, x_{i+k}] - f[x_i, \dots, x_{i+k-1}]}{x_{i+k} - x_i} \end{aligned}$$

\* 均差构造插值多项式：各项为  $f[x_0, x_1, \dots, x_k] \cdot (x - x_0)(x - x_1) \dots (x - x_{k-1})$

- 分段插值：分片线性插值、分片三次 Hermite 插值

– 分片线性插值基函数：

$$L_{\alpha}(x) = \begin{cases} \frac{x - x_{\alpha-1}}{x_{\alpha} - x_{\alpha-1}}, & x \in [x_{\alpha-1}, x_{\alpha}] \\ \frac{x_{\alpha+1} - x}{x_{\alpha+1} - x_{\alpha}}, & x \in [x_{\alpha}, x_{\alpha+1}] \\ 0, & \text{else} \end{cases}$$
$$\phi(x) = \sum_{\alpha=0}^n f_{\alpha} L_{\alpha}(x)$$

– 分片三次 Hermite 插值基函数：

$$\begin{aligned}\alpha_k &= \left(1 + 2 \frac{x - x_k}{x_{k+1} - x_k}\right) \left(\frac{x_{k+1} - x}{x_{k+1} - x_k}\right)^2 \\ \beta_k &= (x - x_k) \left(\frac{x_{k+1} - x}{x_{k+1} - x_k}\right)^2 \\ \alpha_{k+1} &= \left(1 + 2 \frac{x_{k+1} - x}{x_{k+1} - x_k}\right) \left(\frac{x - x_k}{x_{k+1} - x_k}\right)^2 \\ \beta_{k+1} &= -(x_{k+1} - x) \left(\frac{x - x_k}{x_{k+1} - x_k}\right)^2 \\ \phi(x) &= \sum_{k=0}^n [f_k \alpha_k + f'_k \beta_k], \quad x \in [x_k, x_{k+1}]\end{aligned}$$

## (一) 通用理论

### 1. 问题模型

**待填写：(数学描述) 采样泛函视角下的插值问题数学描述**

### 2. 插值空间

常用的插值空间：多项式函数空间、样条函数空间、三角多项式函数空间

### 3. 误差分析与收敛性

## (二) 具体插值方法

### 1. 一维多项式插值

问题：给定插值数据（采样数据） $(x_\alpha, f_\alpha)$ ,  $\alpha \in I$ , 确定多项式  $P(x) \in P_n$ ,  $n = |I| - 1$ , 满足插值条件

$$x_\alpha(P) = P(x_\alpha) = f_\alpha, \quad \alpha \in I$$

**定理** (多项式插值基本定理). 给定  $n + 1$  个插值条件

$$(x_\alpha, f_\alpha), \quad \alpha \in I, \quad x_\alpha \neq x_\beta \text{ for } \alpha \neq \beta$$

则存在唯一的插值多项式  $P \in P_n$  满足插值条件。

Note: 若  $x_\alpha$  取之于复平面, 上述定理依然成立; 且上述定理与采样节点的排序无关。

## (1) Lagrange 插值

### a. 基函数构造

定义 (Lagrange 插值基函数). 定义

$$L_\alpha(x) = L_{\alpha;I}(x) = \prod_{\substack{\beta \in I \\ \beta \neq \alpha}} \frac{x - x_\beta}{x_\alpha - x_\beta}, \quad \alpha \in I$$

称为插值基函数。

若给定 3 个插值条件  $(x_0, f_0)$ ,  $(x_1, f_1)$ ,  $(x_2, f_2)$ , 则对应的插值基函数为

$$\begin{aligned} L_0(x) &= \frac{(x - x_1)(x - x_2)}{(x_0 - x_1)(x_0 - x_2)} \\ L_1(x) &= \frac{(x - x_0)(x - x_2)}{(x_1 - x_0)(x_1 - x_2)} \\ L_2(x) &= \frac{(x - x_0)(x - x_1)}{(x_2 - x_0)(x_2 - x_1)} \end{aligned}$$

插值基函数天然满足性质:

$$x_\beta(L_\alpha) = L_\alpha(x_\beta) = \delta_{\alpha\beta}$$

### b. 插值公式

在计算出插值基函数的基础上, 插值多项式可写为:

$$P(x) = \sum_{\alpha \in I} f_\alpha L_\alpha(x)$$

### c. 余项

### d. 均差定义

定义 (均差的递推公式). 设  $f(x)$  在区间  $[a, b]$  上有定义, 且给定插值节点  $x_0, x_1, \dots, x_n$ , 则定义如下均差:

$$\begin{aligned} f[x_i] &= f(x_i) \\ f[x_i, x_{i+1}, \dots, x_{i+k}] &= \frac{f[x_{i+1}, \dots, x_{i+k}] - f[x_i, \dots, x_{i+k-1}]}{x_{i+k} - x_i} \end{aligned}$$

其中,  $i = 0, 1, \dots, n - k$ ,  $k = 1, 2, \dots, n$ 。

均差的性质:

- $f_{i_0 i_1 \dots i_k}$  与节点  $x_{i_0}, x_{i_1}, \dots, x_{i_k}$  的顺序无关
- 设  $f$  是  $N$  次多项式, 若  $k > N$ , 则对任意节点  $x_{i_0}, x_{i_1}, \dots, x_{i_k}$ , 都有

$$f_{i_0 i_1 \dots i_k} = 0$$

## e. 插值公式

$$P_{i_0 i_1 \dots i_k}(x) = f_{i_0} + f_{i_0 i_1}(x - x_{i_0}) + f_{i_0 i_1 i_2}(x - x_{i_0})(x - x_{i_1}) + \dots \\ + f_{i_0 i_1 \dots i_k}(x - x_{i_0})(x - x_{i_1}) \cdots (x - x_{i_{k-1}})$$

## f. Newton 插值多项式的列表计算

以给定 4 个节点时  $x_0, x_1, x_2, x_3$  的插值问题为例。可以按照如下表格从左向右逐列填写计算均差：

$x_i$	0 阶均差	1 阶均差	2 阶均差	3 阶均差
$x_0$	$f(x_0)$			
		$f[x_0, x_1] = \frac{f(x_1) - f(x_0)}{x_1 - x_0}$		
$x_1$	$f(x_1)$		$f[x_0, x_1, x_2] = \frac{f[x_1, x_2] - f[x_0, x_1]}{x_2 - x_0}$	
		$f[x_1, x_2] = \frac{f(x_2) - f(x_1)}{x_2 - x_1}$		$f[x_0, x_1, x_2, x_3] = \dots$
$x_2$	$f(x_2)$		$f[x_1, x_2, x_3] = \frac{f[x_2, x_3] - f[x_1, x_2]}{x_3 - x_1}$	
		$f[x_2, x_3] = \frac{f(x_3) - f(x_2)}{x_3 - x_2}$		
$x_3$	$f(x_3)$			

之后用插值表最上方一行的均差值逐个组装 Newton 插值多项式。

## (2) Hermite 插值

## a. Hermite 插值问题

给定  $\xi_i, f_i^{(k)}, i = 0, 1, \dots, m, k = 0, 1, \dots, n_i - 1$ , 其中  $\xi_i$  两两不同, 且

$$\xi_0 < \xi_1 < \dots < \xi_m$$

希望确定一个次数为  $n$  的多项式函数

$$P_n(x), \quad n = \sum_{i=0}^m n_i - 1$$

满足插值条件

$$P^{(k)}(\xi_i) = f_i^{(k)}, \quad i = 0, 1, \dots, m \quad k = 0, 1, \dots, n_i - 1$$

## b. 拓展均差

**定义** (拓展均差). 设  $f \in C^n(I(x_0, x_1, \dots, x_n))$ , 定义

$$f[x_0, x_1, x_n] = \int_0^{t_0} dt_1 \int_0^{t_1} dt_2 \cdots \int_0^{t_{n-1}} dt_n$$

$$f^{(n)}(t_n[x_n - x_{n-1}] + t_{n-1}[x_{n-1} - x_{n-2}] + \dots + t_1[x_1 - x_0] + t_0 x_0)$$

式中,  $n \geq 1$  且  $t_0 = 1$ 。

Note: 这一积分实际上表示了一个单位标准  $n$ -维标准型上的积分, 或者说积分区域始终是一个插值节点构造的凸组合。这隐含了一个要求是  $1 = t_0 \geq t_1 \geq t_2 \geq \dots \geq t_n \geq 0$ 。

拓展均差的性质:

- 若  $x_i$  两两不一, 则拓展均差等价于普通均差

$$f[x_0, x_1, x_n] = f_{x_0, x_1, \dots, x_n}$$

且具有相同的递推关系:

$$f[x_0, x_1, \dots, x_n] = \frac{f[x_0, x_1, \dots, x_{n-2}, x_n] - f[x_0, x_1, \dots, x_{n-1}]}{x_n - x_0}$$

- 极限性质: 若  $f$  足够光滑, 则

$$\lim_{\epsilon_i \rightarrow 0} f[x_0 + \epsilon_0, x_1 + \epsilon_1, \dots, x_n + \epsilon_n] = f[x_0, x_1, \dots, x_n]$$

- 导数与重节点: 可从极限性质导出

$$\frac{d}{dx} f[x_0, x_1, \dots, x_n, x] = f[x_0, x_1, \dots, x_n, x, x]$$

- 介值定理: 若  $f \in C^n[a, b]$ ,  $x_0, x_1, \dots, x_n \in [a, b]$ , 则存在  $\xi \in I(x_0, x_1, \dots, x_n)$ , 使得

$$f[x_0, x_1, \dots, x_n] = \frac{f^{(n)}(\xi)}{n!}$$

特别地,

$$f[\underbrace{x, x, \dots, x}_{n+1 \text{ 个}}] = \frac{f^{(n)}(x)}{n!}$$

## c. Hermite 插值多项式

Hermite 插值多项式可表示为

$$P(x) = f[x_0] + f[x_0, x_1](x - x_0) + \dots + f[x_0, x_1, \dots, x_n](x - x_0)(x - x_1) \dots (x - x_{n-1})$$

其中,  $x_0, \dots, x_n$  为下面序列的任意置换:

$$\underbrace{\xi_0, \xi_0, \dots, \xi_0}_{n_0 \text{ 个}}, \underbrace{\xi_1, \xi_1, \dots, \xi_1}_{n_1 \text{ 个}}, \dots, \underbrace{\xi_m, \xi_m, \dots, \xi_m}_{n_m \text{ 个}}$$

#### d. 列表法求 Hermite 插值多项式

假设给定 2 个节点  $\xi_0, \xi_1$ , 对应的插值条件分别为  $f_0, f'_0, f''_0, f_1$ , 则可按下表计算均差:

Hermite 插值均差表 (节点序列:  $\xi_0, \xi_0, \xi_0, \xi_1$ ):

节点	0 阶均差	1 阶均差	2 阶均差	3 阶均差
$\xi_0$	$f[\xi_0] = f_0$			
$\xi_0$	$f[\xi_0] = f_0$	$f[\xi_0, \xi_0] = f'_0$		
$\xi_0$	$f[\xi_0] = f_0$	$f[\xi_0, \xi_0] = f'_0$	$f[\xi_0, \xi_0, \xi_0] = \frac{f''_0}{2}$	
$\xi_1$	$f[\xi_1] = f_1$	$f[\xi_0, \xi_1] = \frac{f_1 - f_0}{\xi_1 - \xi_0}$	$f[\xi_0, \xi_0, \xi_1] = \frac{f[\xi_0, \xi_1] - f[\xi_0, \xi_0]}{\xi_1 - \xi_0}$	$f[\xi_0, \xi_0, \xi_0, \xi_1] = \frac{f[\xi_0, \xi_0, \xi_1] - f[\xi_0, \xi_0, \xi_0]}{\xi_1 - \xi_0}$

对应的插值多项式为:

$$\begin{aligned}
 P(x) &= f[\xi_0] + f[\xi_0, \xi_0](x - \xi_0) + f[\xi_0, \xi_0, \xi_0](x - \xi_0)^2 + f[\xi_0, \xi_0, \xi_0, \xi_1](x - \xi_0)^3 \\
 &= f_0 + f'_0(x - \xi_0) + \frac{f''_0}{2}(x - \xi_0)^2 \\
 &\quad + \frac{2(f_1 - f_0 - f'_0(\xi_1 - \xi_0)) - f''_0(\xi_1 - \xi_0)^2}{2(\xi_1 - \xi_0)^3}(x - \xi_0)^3
 \end{aligned}$$

### (3) Lagrange 插值和 Hermite 插值的收敛分析

#### a. 插值余项

若  $f$  在区间  $[a, b]$  上具有  $n+1$  阶连续导数, 则对任意  $x \in [a, b]$ , 存在  $\xi \in I(x, x_0, x_1, \dots, x_n)$ , 使得

$$R(x) = f(x) - P(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{i=0}^n (x - x_i) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{01\dots n}(x)$$

#### b. 收敛性

收敛性的定义: 当给定插值点的最大间距  $h \rightarrow 0$  时, 插值余项  $R(x) \rightarrow 0$ , 则称插值多项式序列在区间  $[a, b]$  上收敛于函数  $f(x)$ 。

**定义** (多项式插值收敛定义). 设  $f \in C^\infty[a, b]$ , 且存在正常数  $M > 0$ , 使得对任意的  $n \geq 0$ , 都有

$$\max_{x \in [a, b]} |f^{(n)}(x)| \leq M$$

则对任意在  $[a, b]$  上的插值节点序列  $\{x_i^{(n)}\}_{i=0}^n$ , 对应的插值多项式序列  $\{P_n(x)\}$  在  $[a, b]$  上均匀收敛于  $f(x)$ 。

收敛的充分条件:

**定理.** 记  $\delta = |I(x_0, x_1, x_2, \dots, x_n)|$ ,  $\tilde{x}$  为  $I$  的中心. 若  $f$  在  $B(\tilde{x}, w\delta)$  上复解析, 则对任意  $\bar{x} \in I$ , 插值法收敛。



## 2. 分段插值

### (1) 分段线性插值

待填写: () 分片线性插值问题描述

#### a. 分片线性插值的插值基函数

定义 (分片线性插值基函数). 设给定插值节点  $x_0 < x_1 < \dots < x_n$ , 则定义分片线性插值基函数为

$$l_i(x) = \begin{cases} \frac{x-x_{i-1}}{x_i-x_{i-1}}, & x \in [x_{i-1}, x_i] \\ \frac{x_{i+1}-x}{x_{i+1}-x_i}, & x \in [x_i, x_{i+1}] \\ 0, & otherwise \end{cases}$$

其中,  $i = 0, 1, \dots, n$ , 且约定  $x_{-1} = x_0$ ,  $x_{n+1} = x_n$ .

则线性插值基函数为

$$\phi(x) = \sum_{k=1}^n f_k l_k(x)$$

#### b. 分片线性插值的收敛性定理

定义

$$h = \max_{1 \leq i \leq n} (x_i - x_{i-1})$$

- 若  $f \in C[a, b]$ , 则  $\lim_{h \rightarrow 0} \|f - \phi\|_{\infty} \rightarrow 0$
- 若  $f \in C^1[a, b]$ , 则  $\|f - \phi\|_{\infty} \leq \frac{h}{2} \|f'\|_{\infty}$
- 若  $f \in C^2[a, b]$ , 则  $\|f - \phi\|_{\infty} \leq \frac{h^2}{8} \|f''\|_{\infty}$

### (2) 分段三次 Hermite 插值

待填写: () 分片三次 Hermite 插值的数学描述

#### a. 插值基函数

分段三次 Hermite 插值的基函数满足如下条件:

$$\begin{aligned} \alpha_k(x_i) &= \delta_{ik}, & \alpha'_k(x_i) &= 0 \\ \beta_k(x_i) &= 0, & \beta'_k(x_i) &= \delta_{ik} \end{aligned}$$

在单元  $[x_k, x_{k+1}]$  上, 三次 Hermite 插值基函数为

$$\begin{aligned}\alpha_k &= \left(1 + 2 \frac{x - x_k}{x_{k+1} - x_k}\right) \left(\frac{x_{k+1} - x}{x_{k+1} - x_k}\right)^2 \\ \beta_k &= (x - x_k) \left(\frac{x_{k+1} - x}{x_{k+1} - x_k}\right)^2 \\ \alpha_{k+1} &= \left(1 + 2 \frac{x_{k+1} - x}{x_{k+1} - x_k}\right) \left(\frac{x - x_k}{x_{k+1} - x_k}\right)^2 \\ \beta_{k+1} &= -(x_{k+1} - x) \left(\frac{x - x_k}{x_{k+1} - x_k}\right)^2\end{aligned}$$

- $\alpha_k$  满足单位分解性:  $\alpha_k + \alpha_{k+1} = 1$
- $\alpha_k(x_i) = \delta_{ik}, \alpha'_k(x_i) = 0$
- $\beta_k(x_i) = 0, \beta'_k(x_i) = \delta_{ik}$

#### b. 三次 Hermite 插值多项式

$$\phi = \sum_{k=0}^n [f_k \alpha_k(x) + f'_k \beta_k(x)]$$

#### c. 收敛性定理

**定义** (分段三次 Hermite 插值收敛性定理). 设  $f \in C^1[a, b]$ , 则分段三次 Hermite 插值多项式  $\phi$  满足

$$\|f - \phi\|_{\infty} \leq ch \|f'\|_{\infty}$$

若  $f$  有更好的光滑性, 则:

- 若  $f \in C^2[a, b]$ , 则  $\|f - \phi\|_{\infty} \leq ch^2 \|f''\|_{\infty}$
- 若  $f \in C^3[a, b]$ , 则  $\|f - \phi\|_{\infty} \leq ch^3 \|f'''\|_{\infty}$
- 若  $f \in C^4[a, b]$ , 则  $\|f - \phi\|_{\infty} \leq \frac{1}{384} h^4 \|f^{(4)}\|_{\infty}$

此外, 对于不高于三次的多项式, 分段三次 Hermite 插值是精确的。

### 3. Fourier 插值

#### (1) 离散傅里叶变换

**待填写: (定义) 离散傅里叶变换式、变换式系数表达式**

如果  $f$  的光滑性满足  $f \in C_{per}^M$ , 则有

$$\begin{aligned} a_n &= O(n^{-M}) \\ b_n &= O(n^{-M}) \end{aligned}$$

且

$$\|f(x) - \left[ \frac{a_0}{2} + \sum_{n=1}^N a_n \cos nx + \sum_{n=1}^N b_n \sin nx \right]\|_{\infty} = O(N^{-M})$$

## (2) 三角多项式插值空间

三角多项式插值空间为:

$$\begin{aligned} \Phi_{2M+1} &:= \left\{ \frac{A_0}{2} + \sum_{n=1}^M (A_n \cos nx + B_n \sin nx) \right\} \\ \Phi_{2M} &:= \left\{ \frac{A_0}{2} + \sum_{n=1}^{M-1} (A_n \cos nx + B_n \sin nx) + A_M \cos Mx \right\} \end{aligned}$$

## (3) 三角多项式插值与一般多项式插值

待填写: (问题) 三角多项式插值问题的数学描述

待填写: (问题) 辅助插值问题: 找相多项式

待填写: (理论) 两个插值问题之间的联系: 欧拉公式

## (4) 插值定理与三角插值多项式

定理 (三角多项式插值定理). 设给定插值节点

$$x_k = \frac{2k\pi}{N}, \quad k = 0, 1, \dots, N-1$$

则对任意插值数据  $f_k$ , 存在唯一的三角多项式

$$P(x) = \frac{A_0}{2} + \sum_{n=1}^M (A_n \cos nx + B_n \sin nx)$$

(当  $N$  为奇数时,  $M = \frac{N-1}{2}$ ; 当  $N$  为偶数时,  $M = \frac{N}{2}$ ) 满足插值条件

$$P(x_k) = f_k, \quad k = 0, 1, \dots, N-1$$

同样, 存在唯一的相多项式

$$Q(x) = \sum_{n=0}^{N-1} \beta_n e^{inx}$$

满足插值条件

$$Q(x_k) = f_k, \quad k = 0, 1, \dots, N-1$$

- 三角插值多项式：

$$A_j = \frac{2}{N} \sum_{k=0}^{N-1} f_k \cos\left(\frac{2\pi jk}{N}\right), \quad j = 0, 1, \dots, M$$

$$B_j = \frac{2}{N} \sum_{k=0}^{N-1} f_k \sin\left(\frac{2\pi jk}{N}\right), \quad j = 1, 2, \dots, M$$

- 相插值多项式：

$$\beta_j = \frac{1}{N} \sum_{k=0}^{N-1} f_k w^{-kj}, \quad j = 0, 1, \dots, N-1$$

式中,  $w = e^{i\frac{2\pi}{N}}$ 。

## 三 函数逼近

### 总结

Note: 这里为了让总结看起来更顺畅, 没有遵循原 PPT 和书中的符号规范, 转而应用了比较统一的符号。这些符号规范仅在总结一部分使用。

- 最佳平方逼近求解:
  - 给定一组规范正交函数基时:
    - \* 写出规范正交函数基  $\{\phi_m\}_{m=0}^n$
    - \* 计算系数  $a_m = \frac{(f, \phi_m)}{(\phi_m, \phi_m)}$
    - \* 写出逼近多项式  $\phi^* = \sum_{m=0}^n a_m \phi_m$
  - 给定一组非规范正交函数基时:
    - \* 写出非规范正交函数基  $\{\phi_m\}_{m=0}^n$
    - \* 构建法方程组:

$$m_{ij} = (\phi_j, \phi_i), \quad b_i = (f, \phi_i)$$

- \* 求解线性方程组  $\mathbf{M}\mathbf{a} = \mathbf{b}$ , 得到系数  $a_m$
  - \* 写出逼近多项式  $\phi^* = \sum_{m=0}^n a_m \phi_m$
- Legendre 多项式作最佳平方逼近的收敛速度: 高阶时控制在  $1/\sqrt{n}$  以下
- 最小二乘逼近求解: 计算过程可视作最佳平方逼近的离散形式
  - 给定基底  $\{\phi_m\}_{m=0}^n$  和采样点  $\{x_k\}_{k=0}^N$
  - 估计一个误差系数  $\rho(x_i)$
  - 用半内积构建法方程组:

$$m_{ij} = \sum_{k=0}^N \rho(x_k) \phi_j(x_k) \phi_i(x_k), \quad b_i = \sum_{k=0}^N \rho(x_k) f(x_k) \phi_i(x_k)$$

- 求解线性方程组  $\mathbf{Ma} = \mathbf{b}$ , 得到系数  $a_m$
- 写出逼近多项式  $\phi^* = \sum_{m=0}^n a_m \phi_m$
- 一致逼近求解:
  - 给定原函数  $f \in C[a, b]$  和基底  $\{\phi_m\}_{m=0}^n$
  - 写出待定逼近多项式  $\phi(x) = \sum_{m=0}^n a_m \phi_m(x)$
  - 写出误差函数  $E(x) = f(x) - \phi(x)$
  - 根据切比雪夫交错点组定理, 写出求解条件:
    - \* 交错条件:  $E(x_i) = -e(x_{i-1})$
    - \* 偏差点条件: 除端点作为偏差点的情况, 必有  $f'(x_i) = p'_n(x_i)$
  - 由偏差点条件可以解出一系列偏差点  $x_i(\mathbf{a})$ , 再代入交错条件中, 解出系数  $a_m$

## (一) 通用理论

### 1. 问题模型

待填写: (问题) 函数逼近问题的数学模型

最佳逼近问题: 找  $\phi^* \in \Phi$ , 使得

$$\|f - \phi^*\| = \min_{\phi \in \Phi} \|f - \phi\|$$

### 2. 逼近准则

- (1) 最小二乘准则 (L 范数)
- (2) 一致逼近准则 ( $L^\infty$  范数)

### 3. 核心定理

## (二) 具体逼近方法

### 1. 最优平方逼近

#### (1) 基础理论

问题: 给定一个线性子空间  $\Phi$ , 找  $\phi^* \in \Phi$ , 使得

$$\|f - \phi^*\|_2 = \min_{\phi \in \Phi} \|f - \phi\|_2$$

问题等价于

$$\|f - \phi^*\|_2^2 = \min_{\phi \in \Phi} \|f - \phi\|_2^2$$

于是构造出一个辅助函数：

$$\begin{aligned} I = \|f - \phi\|_2^2 &= \left( f - \sum_{i=0}^n a_i \phi_i, f - \sum_{i=0}^n a_i \phi_i \right) \\ &= \sum_{i=0}^n \sum_{j=0}^n a_i a_j (\phi_i, \phi_j) - 2 \sum_{i=0}^n a_i (f, \phi_i) + (f, f) \end{aligned}$$

式中， $\{\phi_i\}$  为  $\Phi$  的一组基。

### a. 法方程

多元函数取得最小值的条件：对各变量偏导为 0、在这一点二阶偏导数构成的矩阵正定。

各变量偏导为 0 即导出法方程：

$$\sum_{j=0}^n a_j (\phi_j, \phi_i) = (f, \phi_i), \quad i = 0, 1, \dots, n$$

或写成矩阵形式，

$$\begin{bmatrix} (\phi_0, \phi_0) & (\phi_1, \phi_0) & \cdots & (\phi_n, \phi_0) \\ (\phi_0, \phi_1) & (\phi_1, \phi_1) & \cdots & (\phi_n, \phi_1) \\ \vdots & \vdots & \ddots & \vdots \\ (\phi_0, \phi_n) & (\phi_1, \phi_n) & \cdots & (\phi_n, \phi_n) \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} (f, \phi_0) \\ (f, \phi_1) \\ \vdots \\ (f, \phi_n) \end{bmatrix}$$

**定理** (最小二乘逼近法方程). 设  $\Phi$  为线性子空间， $\{\phi_0, \phi_1, \dots, \phi_n\}$  为  $\Phi$  的一组基，则函数  $f$  在  $\Phi$  中的最优平方逼近  $\phi^*$  可表示为

$$\phi^* = \sum_{j=0}^n a_j^* \phi_j$$

其中，系数  $c_j^*$  满足法方程组

$$\sum_{j=0}^n a_j (\phi_j, \phi_i) = (f, \phi_i), \quad i = 0, 1, \dots, n$$

### b. 最佳平方逼近的性质

**引理** (最佳平方逼近的正交性质). 设  $\phi^*$  为函数  $f$  在子空间  $\Phi$  中的最佳平方逼近，则对任意  $\phi \in \Phi$ ，都有

$$f - \phi^* \perp \Phi$$

**推论** (最佳平方逼近的勾股定理). 设  $\phi^*$  为函数  $f$  在子空间  $\Phi$  中的最佳平方逼近，则有

$$\|f\|_2^2 = \|f - \phi^*\|_2^2 + \|\phi^*\|_2^2$$

## (2) 幂函数基的逼近

考虑连续函数在  $n$ -次多项式空间  $P_n$  中的最佳平方逼近问题。

若选取  $\{x^m\}_{m=0}^n$  作为基函数, 在  $[0, 1]$  区间上求解最佳平方逼近, 则法方程组的系数矩阵为 Hilbert 矩阵:

**定义** (Hilbert 矩阵). 阶数为  $n+1$  的 Hilbert 矩阵定义为

$$H_{ij} = \frac{1}{i+j-1}, \quad i, j = 1, 2, \dots, n+1$$

即

$$H_n = \begin{bmatrix} 1 & \frac{1}{2} & \frac{1}{3} & \cdots & \frac{1}{n+1} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \cdots & \frac{1}{n+2} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \cdots & \frac{1}{n+3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \frac{1}{n+1} & \frac{1}{n+2} & \frac{1}{n+3} & \cdots & \frac{1}{2n+1} \end{bmatrix}$$

这一逼近形式的问题:

- Hilbert 矩阵病态, 随着  $n$  的增大, 条件数迅速增大, 导致数值解不稳定
- 幂函数基不正交, 导致法方程系数矩阵接近奇异

## (3) 正交多项式逼近

### a. 广义傅里叶展开

在  $C[a, b]$  中, 取一个规范正交函数组  $\{\phi_m\}_{m=0}^n$ , 即确定了一个用于逼近的线性子空间  $\Phi_n = \text{span}\{\phi_0, \phi_1, \dots, \phi_n\}$ 。

相应地, 对于任意给定函数  $f$ , 存在唯一的最佳平方逼近  $\phi^* \in \Phi_n$ , 且

$$\phi^* = \sum_{i=0}^n a_i^* \phi_i, \quad a_i^* = (f, \phi_i)$$

**定义** (广义傅里叶展开). 设  $\{\phi_m\}_{m=0}^\infty$  为  $C[a, b]$  中的规范正交函数组, 则对任意  $f \in C[a, b]$ , 都有

$$f \sim f_\infty = \sum_{i=0}^\infty a_i \phi_i, \quad a_i = (f, \phi_i)$$

$f_\infty$  称为函数  $f$  在  $\{\phi_m\}$  下的广义傅里叶展开。

**定理** (广义傅里叶展开的收敛性). 设  $\{\phi_m\}_{m=0}^\infty$  为  $C[a, b]$  中的规范正交函数组, 则对任意  $f \in C[a, b]$ , 其广义傅里叶展开在  $L_2$  范数下收敛于  $f$ , 即

$$\lim_{n \rightarrow \infty} \|f - f_n\|_2 = 0$$

其中,  $f_n = \sum_{i=0}^n a_i \phi_i$ 。



## b. Legendre 多项式作最佳平方逼近

设内积为  $[-1, 1]$  上的权 1 内积, 给定  $f \in C[-1, 1]$ , 则  $f$  在 Legendre 多项式空间  $P_n$  中的最佳平方逼近为

$$I_n f(x) = \sum_{k=0}^n \frac{(f, \phi_k)}{\|\phi_k\|^2} \phi_k(x)$$

性质:

- 收敛性:  $I_n f \rightarrow f$ ,  $n \rightarrow \infty$ , 且收敛到  $L^2((-1, 1))$  空间中
- 收敛速度估计: 若  $f \in C^2[-1, 1]$ , 则  $\forall \epsilon > 0, \exists N > 0$ , 使得

$$\|f - I_n f\|_\infty \leq \frac{\epsilon}{\sqrt{n}}, \quad n \geq N$$

即对于  $n$  次的 Legendre 多项式逼近, 误差会被控制在  $O(\frac{1}{\sqrt{n}})$  范围内

## (4) Legendre 多项式的零平方误差最小性质

**定理** (Legendre 多项式的零平方误差最小性质). 设  $f \in C[-1, 1]$ , 则在所有满足  $\deg(p_n) \leq n$  且  $(p_n, x^k) = 0, \quad k = 0, 1, \dots, n-1$  的多项式中, Legendre 多项式  $P_n(x)$  使得平方误差  $\|f - P_n\|_2$  最小。

## 2. 最小二乘逼近: 最优平方逼近的离散化形式

**待填写: (问题) 最小二乘逼近的问题模型: 确定的输入-输出关系叠加系统噪声和随机误差, 希望拟合输入-输出关系的具体形式**

### (1) 基础理论

核心假设: 观测数据  $f_i$  和正确值  $\phi^*(x_i)$  之间的误差  $a_i \xi_i$  是一个独立同分布的零均值随机变量。

假设导出: 当拟合结果  $\phi$  取得正确的关系  $\phi = \phi^*$  时, (归一化) 误差的方差最小。

数学化:  $\phi^*$  是以下优化问题的极小解:

$$\phi^* = \arg \min_{\phi \in \Phi} \sigma^2 = \arg \min_{\phi \in \Phi} \frac{1}{m+1} \sum_{i=0}^m [f_i - \phi(x_i)]^2$$

### (2) 数学方法: “半” 内积

**定理** (Haar 条件). 若给定一组采样点  $\{x_i\}_{i=0}^m$ , 且  $\Phi$  中的任意非 0 元素在这组采样点上的采样结果不全为 0, 则称这组采样点满足 Haar 条件。

满足 Haar 条件时, 可以利用在采样点上的采样结果, 定义一个 “半” 内积:

$$(f, g)_m = \sum_{i=0}^m \frac{f(x_i)g(x_i)}{a_i^2}$$

此时这个“半”内积在  $\Phi$  上是一个真正的内积。因此上述问题等价于求解法方程  $AU=b$ :

$$\begin{bmatrix} (\phi_0, \phi_0)_m & (\phi_1, \phi_0)_m & \cdots & (\phi_n, \phi_0)_m \\ (\phi_0, \phi_1)_m & (\phi_1, \phi_1)_m & \cdots & (\phi_n, \phi_1)_m \\ \vdots & \vdots & \ddots & \vdots \\ (\phi_0, \phi_n)_m & (\phi_1, \phi_n)_m & \cdots & (\phi_n, \phi_n)_m \end{bmatrix} \begin{bmatrix} u_0 \\ u_1 \\ \vdots \\ u_n \end{bmatrix} = \begin{bmatrix} (f, \phi_0)_m \\ (f, \phi_1)_m \\ \vdots \\ (f, \phi_n)_m \end{bmatrix}$$

Note: 我们注意到, 在求内积过程中, 分母上表示采样点随机误差幅度的  $a_i^2$  仍然是不确定的, 此时需要基于经验或先验知识给出估计。常用的估计有  $a_i \propto 1$ 、 $a_i \propto f_i$ 、 $a_i \propto x_i$ 、 $a_i \propto x_i^2$  等。

### 3. 最佳一直逼近

**待填写: (问题) 最佳一直逼近的数学描述**

最佳一直逼近中用到一些符号:

- $\Delta(f, p_n) = \|f - p_n\|_\infty$  称为  $p_n$  关于  $f$  的偏差
- $E_n = \inf_{p_n \in P_n} \Delta(f, p_n)$  称为  $f$  在  $P_n$  中的最小偏差
- 若  $f(x_i) - p_n(x_i) = \sigma \Delta(f, p_n)$ ,  $\sigma = \pm 1$ , 则称  $x_i$  为  $p_n$  关于  $f$  的偏差点。
  - 若  $\sigma = 1$ , 则称  $x_i$  为正偏差点
  - 若  $\sigma = -1$ , 则称  $x_i$  为负偏差点

#### (1) 偏差泛函与最优逼近多项式存在性定理

假设给定一个逼近多项式  $p_n = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$ , 则可定义偏差泛函:

$$\phi(f, \mathbf{a}) = \|f - p_n\|_\infty = \|f - (a_0 + a_1x + \dots + a_nx^n)\|_\infty$$

这个泛函具有以下性质:

- 连续性:  $\phi$  对  $\mathbf{a}$  连续
- 对  $\mathbf{a}$  下凸:  $\forall \mathbf{a}_1, \mathbf{a}_2 \in \mathbb{R}^{n+1}$ ,  $\forall t \in [0, 1]$ , 都有

$$\phi(f, t\mathbf{a}_1 + (1-t)\mathbf{a}_2) \leq t\phi(f, \mathbf{a}_1) + (1-t)\phi(f, \mathbf{a}_2)$$

- 正定性: 对于任意  $\mathbf{a} \neq \mathbf{0}$ , 都有  $\phi(f, \mathbf{a}) > 0$

正定性等价于:  $\phi(0; \mathbf{a})$  在单位球面  $\sum_{i=0}^n a_i^2 = 1$  上有正的最小值  $\mu$

利用偏差泛函的性质, 可以证明最佳一直逼近多项式的存在性:

**定理** (最佳一致逼近存在性定理). 设  $f \in C[a, b]$ , 则在  $n$  次多项式空间  $P_n$  中, 存在一个多项式  $p_n^* \in P_n$ , 使得

$$\|f - p_n^*\|_\infty = \min_{p_n \in P_n} \|f - p_n\|_\infty$$

即  $P_n$  中关于  $f \in C[a, b]$  的最小偏差是可以达到的。

## (2) 最佳一致逼近多项式的性质

**定义** (Chebyshev 交错点组). 若  $x_1 < x_2 < \dots < x_m$  是  $p_n$  关于  $f$  的轮流为正负的偏差点, 则称其为一个 Chebyshev 交错点组。

**定理** (最佳一致逼近多项式的 Chebyshev 交错定理).  $p_n^*$  是  $f$  的最佳一致逼近多项式的充要条件是存在一个元素个数为  $n+2$  的 Chebyshev 交错点组  $x_0 < x_1 < \dots < x_{n+1}$

**推论**. 最佳一致逼近多项式是一个 Lagrange 插值多项式, 其插值节点在  $(a, b)$  内。

## (3) 唯一性定理

**定理** (最佳一致逼近多项式的唯一性定理). 设  $f \in C[a, b]$ , 则  $f$  在  $n$  次多项式空间  $P_n$  中的最佳一致逼近多项式  $p_n^*$  是唯一的。

## (4) Chebyshev 多项式的零一致误差最小性质

**定理** (Chebyshev 多项式的零一致误差最小性质). 设  $T_n(x)$  为  $n$  次 Chebyshev 多项式, 则在  $[-1, 1]$  上, 任意单位首项系数的  $n$  次多项式  $p_n(x)$  均满足

$$\|p_n\|_{\infty} \geq \|T_n\|_{\infty} = \frac{1}{2^{n-1}}$$

即 Chebyshev 多项式在  $[-1, 1]$  上具有最小的无穷范数。





## 四 数值微积分

### (一) 数值积分

#### 1. 通用理论

- (1) 积分问题模型
- (2) 求积公式核心
- (3) 代数精度
- (4) 稳定性

#### 2. 具体求积方法

##### (1) Newton-Cotes 公式

- a. 梯形公式
- b. Simpson 公式
- c. 3/8 - 规则

##### (2) 复合求积方法

- a. 复合梯形公式
- b. 复合 Simpson 公式

##### (3) 加速方法

- a. Romberg 方法

##### (4) Gauss 型求积

- a. Gauss 点与权系数
- b. Gauss-Legendre 求积
- c. Gauss-Chebyshev 求积

##### (5) 特殊积分处理



## 五 非线性方程求根

### （一）通用理论

1. 问题模型
2. 迭代法基础
3. 收敛性分析
  - (1) 收敛阶定义
  - (2) 整体收敛性（压缩映像原理）
  - (3) 局部收敛性判定
4. 收敛效率

### （二）具体方法

1. 单步法
  - (1) 牛顿法
    - a. 迭代公式
    - b. 收敛性分析
    - c. 重根处理
  - (2) 不动点迭代
2. 多步法
  - (1) 割线法
3. 其他方法
  - (1) Steffensen 方法
  - (2) Broyden 秩 1 方法





## 六 常微分方程初值问题数值解法

### （一） 通用理论

#### 1. 问题模型

#### 2. 数值解法核心

#### 3. 基本概念

##### （1）局部截断误差与整体截断误差

##### （2）收敛性与收敛阶

##### （3）稳定性与相容性

#### 4. 收敛性与稳定性判定

### （二） 具体方法

#### 1. 单步法

##### （1）Euler 方法

###### a. 向前欧拉

###### b. 向后欧拉

##### （2）改进欧拉方法

##### （3）龙格 - 库塔（RK）方法

###### a. 2 阶 RK 方法

###### b. 4 阶 RK 方法

#### 2. 多步法

##### （1）Adams 方法

###### a. 显式 Adams 公式

## 七 线性代数方程组数值解法

### (一) 线性代数方程组直接解法 (Direct Methods)

#### 1. 基本概念

求解  $Ax = b$ , 其中  $A \in \mathbb{R}^{n \times n}$  非奇异。

##### (1) Cramer 法则 (Cramer's Rule)

即直接求逆

**定理** (Cramer 法则). 若  $\det(A) \neq 0$ , 则  $x_i = \det(A_i) / \det(A)$ 。

**备注.** 理论重要但计算不可行 ( $O((n+1)!)$ ), 仅用于极小规模或理论证明。

#### 2. Gauss 消去法 (Gauss Elimination)

##### (1) 前向消去与回代

求解  $Ax = b$  分为两个阶段:

1. **消元过程 (Forward Elimination):** 将增广矩阵  $[A|b]$  变换为上三角形式  $[U|y]$ 。对于第  $k$  步 ( $k = 1, 2, \dots, n-1$ ):

- **计算乘子:** 设主元  $a_{kk}^{(k)} \neq 0$ , 对所有  $i = k+1, \dots, n$ :

$$m_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}$$

- **行变换:** 将第  $i$  行减去第  $k$  行的  $m_{ik}$  倍, 消去  $a_{ik}^{(k)}$ :

$$a_{ij}^{(k+1)} = a_{ij}^{(k)} - m_{ik} a_{kj}^{(k)}, \quad j = k+1, \dots, n$$

$$b_i^{(k+1)} = b_i^{(k)} - m_{ik} b_k^{(k)}$$

经过  $n-1$  步后, 得到上三角矩阵  $U = A^{(n)}$  和变换后的右端项  $y = b^{(n)}$ 。

2. 回代过程 (Backward Substitution): 求解上三角方程组  $Ux = y$ 。

$$\begin{cases} u_{11}x_1 + u_{12}x_2 + \cdots + u_{1n}x_n = y_1 \\ \cdots \\ u_{nn}x_n = y_n \end{cases}$$

计算公式为:

$$x_n = \frac{y_n}{u_{nn}}$$

$$x_i = \frac{1}{u_{ii}} \left( y_i - \sum_{j=i+1}^n u_{ij}x_j \right), \quad i = n-1, \dots, 1$$

## (2) 选主元策略 (Pivoting)

若主元  $|a_{kk}^{(k)}|$  过小, 乘子  $m_{ik}$  会很大, 导致舍入误差剧烈放大。

- 列主元消去法: 交换行, 使  $\max_{i \geq k} |a_{ik}^{(k)}|$  所在行成为当前主行。
- 全主元消去法: 交换行和列, 选主子阵最大值。
- 数值稳定性: 选主元是保证 Gauss 消去法数值稳定的必要条件。

## 3. 矩阵三角分解 (Matrix Factorization)

### (1) LU 分解

**定理** (存在唯一性). 若  $A$  的所有顺序主子式非零, 则  $A$  可唯一分解为  $A = LU$ , 其中  $L$  为单位下三角阵,  $U$  为上三角阵。

**说明.** 消去步的矩阵表示

在 Gauss 消去的第  $k$  步, 我们通过行变换将第  $k$  列对角线以下的元素消为 0。这一步等价于左乘一个初等下三角矩阵 (Atomic Lower Triangular Matrix)  $L_k$ :

$$L_k = I - \mathbf{m}_k \mathbf{e}_k^T = \begin{bmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -m_{k+1,k} & 1 & \\ & & \vdots & & \ddots \\ & & -m_{n,k} & & & 1 \end{bmatrix}$$

其中  $\mathbf{m}_k = [0, \dots, 0, m_{k+1,k}, \dots, m_{n,k}]^T$  是由第  $k$  步的乘子构成的向量,  $\mathbf{e}_k$  是单位向量。

整个消去过程可以写成:

$$L_{n-1}L_{n-2} \cdots L_1 A = U$$

**说明.** 逆矩阵的性质

$L_k$  的逆矩阵  $L_k^{-1}$  非常简单, 只需将乘子的符号取反:

$$L_k^{-1} = (I - \mathbf{m}_k \mathbf{e}_k^T)^{-1} = I + \mathbf{m}_k \mathbf{e}_k^T$$

这是因为  $(I - \mathbf{m}_k \mathbf{e}_k^T)(I + \mathbf{m}_k \mathbf{e}_k^T) = I - \mathbf{m}_k (\mathbf{e}_k^T \mathbf{m}_k) \mathbf{e}_k^T = I$  (注意  $\mathbf{e}_k^T \mathbf{m}_k = 0$ , 因为  $\mathbf{m}_k$  前  $k$  个元素为 0)。

**说明.** 构造  $L$  矩阵

由  $L_{n-1} \dots L_1 A = U$ , 我们有:

$$A = (L_{n-1} \dots L_1)^{-1} U = L_1^{-1} L_2^{-1} \dots L_{n-1}^{-1} U$$

令  $L = L_1^{-1} L_2^{-1} \dots L_{n-1}^{-1}$ 。神奇的是, 计算这个乘积不需要复杂的矩阵运算。由于  $L_k^{-1}$  的非零乘子位于第  $k$  列,  $L_j^{-1}$  的位于第  $j$  列 ( $j > k$ ), 它们的乘积只是简单地将各列的乘子填充到单位矩阵对应的位置, 互不干扰:

$$L = \left( I + \sum_{k=1}^{n-1} \mathbf{m}_k \mathbf{e}_k^T \right) = \begin{bmatrix} 1 & & & & \\ m_{21} & 1 & & & \\ m_{31} & m_{32} & 1 & & \\ \vdots & \vdots & \ddots & \ddots & \\ m_{n1} & m_{n2} & \dots & m_{n,n-1} & 1 \end{bmatrix}$$

**结论:**  $L$  矩阵的下三角部分正是 Gauss 消去过程中计算出的所有乘子  $m_{ik}$ 。

### a. LU 分解的应用形式

一旦得到  $A = LU$ , 求解  $Ax = b$  变为两步:

1. 解下三角方程组  $Ly = b$  (前代)。
2. 解上三角方程组  $Ux = y$  (回代)。

## (2) Cholesky 分解 ( $LL^T$ )

针对对称正定矩阵 (SPD) 的高效分解。

矩阵  $A$  存在  $LL^T$  分解 (其中  $l_{ii} > 0$ )  $\iff A$  是对称正定的。

## (3) 附: 对称正定矩阵 (SPD) 的判定方法

1. **定义法:**  $A$  是对称矩阵 ( $A^T = A$ ), 且对任意非零向量  $x \neq 0$ , 都有二次型  $x^T A x > 0$ 。
2. **特征值判别法:**  $A$  是对称矩阵, 且  $A$  的所有特征值  $\lambda_i$  均严格大于零 ( $\lambda_i > 0, \forall i$ )。
3. **顺序主子式判别法 (Sylvester 准则):**  $A$  的所有顺序主子式  $\det(A_k)$  均严格大于零 ( $k = 1, \dots, n$ )。

4. **Cholesky 分解存在性**: 若 Cholesky 分解算法能够顺利执行到底, 且所有对角元  $l_{ii}$  均为实数且非零 (即开方过程未遇到负数或零), 则  $A$  必为对称正定矩阵。这也是计算机程序中判断 SPD 的最实用方法。

**定理**. 若  $A$  对称正定, 则存在唯一的对角元  $> 0$  的下三角阵  $L$  使得  $A = LL^T$ 。此外, Cholesky 分解是数值稳定的, 无需选主元 (因为  $|l_{ij}|^2 \leq \sum l_{ik}^2 = a_{ii}$ , 元素不会增长)。

- **算法推导**: 比较  $A = LL^T$  两边的元素:

$$a_{ij} = \sum_{k=1}^n l_{ik}(L^T)_{kj} = \sum_{k=1}^{\min(i,j)} l_{ik}l_{jk}$$

- **计算公式** (按列计算): 对于  $j = 1, \dots, n$ :

1. **对角元**:

$$l_{jj} = \sqrt{a_{jj} - \sum_{k=1}^{j-1} l_{jk}^2}$$

2. **非对角元** ( $i > j$ ):

$$l_{ij} = \frac{1}{l_{jj}} \left( a_{ij} - \sum_{k=1}^{j-1} l_{ik}l_{jk} \right)$$

- **改进:  $LDL^T$  分解 (针对非正定对称阵)**: 如果  $A$  仅仅是对称的 (可能是未定或不定的), 但其顺序主子式非零, 可以进行  $A = LDL^T$  分解, 其中  $L$  是单位下三角,  $D$  是对角阵 (对角元可正可负)。

$$d_j = a_{jj} - \sum_{k=1}^{j-1} d_k l_{jk}^2, \quad l_{ij} = \frac{1}{d_j} \left( a_{ij} - \sum_{k=1}^{j-1} d_k l_{ik}l_{jk} \right)$$

这种方法避免了开方, 适用于更广泛的对称矩阵, 但若遇到  $d_j \approx 0$  仍需选主元 (对称选主元  $PAP^T = LDL^T$ )。

#### (4) 追赶法 (Thomas Algorithm)

针对三对角矩阵的  $LU$  分解简化版 (待补充)。

## 4. 误差分析与条件数

### (1) 条件数 (Condition Number)

衡量方程组解对数据扰动的敏感程度。

$$\text{cond}(A) = \|A\| \cdot \|A^{-1}\|$$

**性质**. 1.  $\text{cond}(A) \geq 1$ . 2. 若  $A$  酉相似于  $B$ , 则  $\text{cond}_2(A) = \text{cond}_2(B)$ . 3. 对于 SPD 矩阵,  $\text{cond}_2(A) = \frac{\lambda_{\max}}{\lambda_{\min}}$ .

## (2) 扰动误差界定理

设  $Ax = b$ ,  $A$  非奇异。考虑  $(A + \delta A)(x + \delta x) = b + \delta b$ 。若满足条件  $\|\delta A\| \cdot \|A^{-1}\| < 1$  (保证  $A + \delta A$  非奇异), 则有如下相对误差界:

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\text{cond}(A)}{1 - \text{cond}(A) \frac{\|\delta A\|}{\|A\|}} \left( \frac{\|\delta A\|}{\|A\|} + \frac{\|\delta b\|}{\|b\|} \right)$$

证明.

$$(A + \delta A)(x + \delta x) = b + \delta b$$

展开得:

$$Ax + A\delta x + \delta Ax + \delta A\delta x = b + \delta b$$

由于  $Ax = b$ , 消去得:

$$(A + \delta A)\delta x = \delta b - \delta Ax$$

两边左乘  $(A + \delta A)^{-1}$ :

$$\delta x = (A + \delta A)^{-1}(\delta b - \delta Ax)$$

利用范数放缩取范数:

$$\|\delta x\| \leq \|(A + \delta A)^{-1}\| \cdot (\|\delta b\| + \|\delta A\| \cdot \|x\|)$$

根据前面的逆矩阵扰动定理:

$$\|(A + \delta A)^{-1}\| \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\| \cdot \|\delta A\|}$$

代入上式:

$$\|\delta x\| \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\| \cdot \|\delta A\|} (\|\delta b\| + \|\delta A\| \cdot \|x\|)$$

两边除以  $\|x\|$ :

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\| \cdot \|\delta A\|} \left( \frac{\|\delta b\|}{\|x\|} + \|\delta A\| \right)$$

利用  $b = Ax \Rightarrow \|b\| \leq \|A\| \cdot \|x\| \Rightarrow \frac{1}{\|x\|} \leq \frac{\|A\|}{\|b\|}$ :

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\| \cdot \|\delta A\|} \left( \frac{\|\delta b\| \cdot \|A\|}{\|b\|} + \|\delta A\| \right)$$

**Step 6: 引入条件数**提取  $\|A\|$ , 并利用  $\text{cond}(A) = \|A\| \cdot \|A^{-1}\|$ :

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\|A^{-1}\| \cdot \|A\|}{1 - \|A^{-1}\| \cdot \|A\| \cdot \frac{\|\delta A\|}{\|A\|}} \left( \frac{\|\delta b\|}{\|b\|} + \frac{\|\delta A\|}{\|A\|} \right)$$

整理得:

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\text{cond}(A)}{1 - \text{cond}(A) \frac{\|\delta A\|}{\|A\|}} \left( \frac{\|\delta A\|}{\|A\|} + \frac{\|\delta b\|}{\|b\|} \right)$$

证毕。 □

### (3) 后验误差估计 (Posteriori Error Estimation)

问题：如何利用计算出的近似解  $\tilde{x}$  来估计真实误差  $x - \tilde{x}$ ？

设  $\tilde{x}$  为近似解，定义残差 (Residual) 为：

$$r = b - A\tilde{x}$$

**定理** (基于残差的误差界). 设  $A$  非奇异，则相对误差与相对残差之间满足如下不等式：

$$\frac{1}{\text{cond}(A)} \frac{\|r\|}{\|b\|} \leq \frac{\|x - \tilde{x}\|}{\|x\|} \leq \text{cond}(A) \frac{\|r\|}{\|b\|}$$

**证明. 1. 上界：** 由  $r = b - A\tilde{x} = Ax - A\tilde{x} = A(x - \tilde{x})$ ，可得：

$$x - \tilde{x} = A^{-1}r \implies \|x - \tilde{x}\| \leq \|A^{-1}\| \cdot \|r\|$$

又由  $Ax = b \implies \|b\| \leq \|A\| \cdot \|x\| \implies \frac{1}{\|x\|} \leq \frac{\|A\|}{\|b\|}$ 。两式相乘：

$$\frac{\|x - \tilde{x}\|}{\|x\|} \leq \|A^{-1}\| \cdot \|r\| \cdot \frac{\|A\|}{\|b\|} = \text{cond}(A) \frac{\|r\|}{\|b\|}$$

**2. 下界：** 由  $r = A(x - \tilde{x}) \implies \|r\| \leq \|A\| \cdot \|x - \tilde{x}\| \implies \|x - \tilde{x}\| \geq \frac{\|r\|}{\|A\|}$ 。又由  $x = A^{-1}b \implies \|x\| \leq \|A^{-1}\| \cdot \|b\| \implies \frac{1}{\|x\|} \geq \frac{1}{\|A^{-1}\| \cdot \|b\|}$ 。两式相乘：

$$\frac{\|x - \tilde{x}\|}{\|x\|} \geq \frac{\|r\|}{\|A\| \cdot \|A^{-1}\| \cdot \|b\|} = \frac{1}{\text{cond}(A)} \frac{\|r\|}{\|b\|}$$

证毕。 □

**备注** (物理意义). 1. **残差小  $\neq$  误差小**：如果  $\text{cond}(A)$  很大 (矩阵病态)，即使残差  $\|r\|$  很小 (计算机解出的方程组几乎“满足”方程)，解的误差  $\|x - \tilde{x}\|$  也可能非常大。这说明对于病态方程组，仅仅看残差是不够的。

2. **迭代改善 (Iterative Refinement)**：利用残差可以提高解的精度。计算  $r = b - A\tilde{x}$  (需用高精度计算)，解修正方程  $Ae = r$ ，则新解  $x_{\text{new}} = \tilde{x} + e$  会更精确。

### (4) 病态矩阵 (Ill-conditioned Matrix)

条件数很大的矩阵。

**例题** (Hilbert 矩阵).

$$H_{ij} = \frac{1}{i + j - 1}$$

$H_n$  高度病态。当  $n$  稍大时， $\text{cond}(H_n)$  极大，直接法解将完全失真。

## 5. 广义逆与正则化 (Generalized Inverse & Regularization)

针对奇异或极度病态方程组 (参考第二章讲义)



## (1) Moore-Penrose 广义逆

对于  $A \in \mathbb{C}^{m \times n}$  (秩  $r$ )，存在唯一的  $A^\dagger$  满足 Penrose 方程。

- **最小二乘解**：方程组  $Ax = b$  的最小二乘解集为  $S = \{x | A^H Ax = A^H b\}$ 。
- **广义逆解**： $x = A^\dagger b$  是  $S$  中 2-范数最小的解。
- **SVD 计算**：若  $A = U\Sigma V^H$ ，则

$$A^\dagger = V\Sigma^\dagger U^H$$

其中  $\Sigma^\dagger = \text{diag}(\sigma_1^{-1}, \dots, \sigma_r^{-1}, 0, \dots, 0)$ 。

## (2) Tikhonov 正则化

用于处理严重的病态问题（如第一类 Fredholm 积分方程离散化）。

- **变分原理**：最小化带罚项的泛函：

$$J_\alpha(x) = \|Ax - b\|_2^2 + \alpha \|x\|_2^2$$

其中  $\alpha > 0$  为正则化参数。

- **正规方程**：

$$(\alpha I + A^H A)x_\alpha = A^H b$$

- **效果**：矩阵  $\alpha I + A^H A$  的条件数比  $A^H A$  改善很多（特征值整体平移  $\alpha$ ），解更稳定。
- **收敛性**：当  $\alpha \rightarrow 0$  时， $x_\alpha \rightarrow A^\dagger b$ 。

# (二) 单步定常线性迭代解法 (Stationary Linear Iterative Methods)

## 1. 迭代法基础理论

### (1) 迭代法的基本概念

- **构造思想**：对于大规模稀疏方程组  $Ax = b$ ，直接法计算代价过高。迭代法通过构造向量序列  $\{x^{(k)}\}$ ，使其极限为方程的解。

$$\lim_{k \rightarrow \infty} x^{(k)} = x^*$$

- **单步定常线性迭代**：迭代格式为：

$$x^{(k+1)} = Bx^{(k)} + f$$

其中  $B$  称为**迭代矩阵**， $f$  为常向量。这种格式只依赖于前一步  $x^{(k)}$  (单步)，且  $B$  和  $f$  不随  $k$  变化 (定常)。

- **构造方法 (矩阵分裂)**：将  $A$  分裂为  $A = M - N$ ，其中  $M$  是非奇异的“近似”矩阵 (易于求逆，如对角阵或三角阵)。

$$Ax = b \iff (M - N)x = b \iff Mx = Nx + b$$

由此导出的迭代格式为：

$$Mx^{(k+1)} = Nx^{(k)} + b \implies x^{(k+1)} = M^{-1}Nx^{(k)} + M^{-1}b$$

此时迭代矩阵  $B = M^{-1}N$ ，常向量  $f = M^{-1}b$ 。

- **Richardson 迭代**：最简单的迭代格式，取  $M = \frac{1}{\omega}I$ 。

$$x^{(k+1)} = x^{(k)} + \omega(b - Ax^{(k)}) = (I - \omega A)x^{(k)} + \omega b$$

迭代矩阵  $B = I - \omega A$ 。收敛条件： $0 < \omega < \frac{2}{\lambda_{\max}(A)}$  (假设  $A$  为 SPD)。

- **预处理迭代**：若引入预处理矩阵  $M \approx A$ ，则 Richardson 迭代变为：

$$x^{(k+1)} = x^{(k)} + \omega M^{-1}(b - Ax^{(k)})$$

这等价于对预处理后的方程  $M^{-1}Ax = M^{-1}b$  进行 Richardson 迭代。

## (2) 向量序列的收敛性

**定义 (序列收敛)**。设  $\{x^{(k)}\}_{k=0}^{\infty}$  是赋范空间  $(\mathbb{R}^n, \|\cdot\|)$  中的向量序列。若存在  $x \in \mathbb{R}^n$ ，使得

$$\lim_{k \rightarrow \infty} \|x^{(k)} - x\| = 0$$

则称序列  $\{x^{(k)}\}$  收敛于  $x$ ，记为  $\lim_{k \rightarrow \infty} x^{(k)} = x$ 。

**定理 (收敛性的等价性)**。 1. **范数无关性**：由于有限维空间  $\mathbb{R}^n$  上的所有范数都是等价的，因此向量序列的收敛性与具体选择的范数无关。如果一个序列在某种范数下收敛，它在任意范数下都收敛。

2. **分量收敛性**：向量序列  $\{x^{(k)}\}$  收敛于  $x$  的充要条件是其每一个分量序列都收敛于  $x$  的对应分量。

$$\lim_{k \rightarrow \infty} x^{(k)} = x \iff \lim_{k \rightarrow \infty} x_i^{(k)} = x_i, \quad \forall i = 1, \dots, n$$

### (3) 迭代误差与收敛速度

设精确解为  $x^*$ ，第  $k$  步误差为  $e^{(k)} = x^{(k)} - x^*$ 。

- 误差传播方程：

$$e^{(k+1)} = x^{(k+1)} - x^* = (Bx^{(k)} + f) - (Bx^* + f) = B(x^{(k)} - x^*) = Be^{(k)}$$

递推可得：

$$e^{(k)} = B^k e^{(0)}$$

- **Jordan 标准型分析与收敛充要条件**：将  $B$  转化为 Jordan 标准型  $B = PJP^{-1}$ ，则  $B^k = PJ^kP^{-1}$ 。对于 Jordan 块  $J_i(\lambda_i)$ ：

$$J_i^k = \begin{bmatrix} \lambda_i^k & \binom{k}{1}\lambda_i^{k-1} & \cdots \\ & \lambda_i^k & \binom{k}{1}\lambda_i^{k-1} \\ & & \ddots \end{bmatrix}$$

要使  $B^k \rightarrow 0$ （即  $e^{(k)} \rightarrow 0$  对任意初值成立），充要条件是所有特征值的模  $|\lambda_i| < 1$ 。即 **谱半径条件**： $\rho(B) < 1$ 。

- **平均收敛率 (Average Rate of Convergence)**：考查前  $k$  步误差范数的平均衰减：

$$\frac{\|e^{(k)}\|}{\|e^{(0)}\|} \leq \|B^k\| \approx \rho(B)^k$$

定义  $k$  步平均收敛率为：

$$R_k(B) = -\frac{1}{k} \ln \|B^k\|$$

- **渐进收敛率 (Asymptotic Rate of Convergence)**：当  $k \rightarrow \infty$  时，利用 Gelfand 半径公式  $\lim_{k \rightarrow \infty} \|B^k\|^{1/k} = \rho(B)$ ，可得：

$$R(B) = \lim_{k \rightarrow \infty} R_k(B) = -\ln \rho(B)$$

**意义**： $R(B)$  越大（即  $\rho(B)$  越小），收敛越快。若要使误差减小  $10^{-m}$  倍（增加  $m$  位有效数字），所需迭代次数  $k$  约为：

$$k \approx \frac{m \ln 10}{R(B)}$$

## 2. 经典迭代方法

将  $A$  分解为  $A = D - L - U$ ：

- $D$ ：对角部分。
- $-L$ ：严格下三角部分。
- $-U$ ：严格上三角部分。

### (1) Jacobi 迭代

- 分裂:  $M = D, \quad N = L + U$ 。
- 公式:  $Dx^{(k+1)} = (L + U)x^{(k)} + b$ 。
- 分量形式:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j \neq i} a_{ij} x_j^{(k)} \right)$$

- 迭代矩阵:  $B_J = D^{-1}(L + U)$ 。

### (2) Gauss-Seidel 迭代

- 思想: 计算  $x_i^{(k+1)}$  时, 利用已更新的  $x_1^{(k+1)}, \dots, x_{i-1}^{(k+1)}$ 。
- 分裂:  $M = D - L, \quad N = U$ 。
- 公式:  $(D - L)x^{(k+1)} = Ux^{(k)} + b$ 。
- 分量形式:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j < i} a_{ij} x_j^{(k+1)} - \sum_{j > i} a_{ij} x_j^{(k)} \right)$$

- 迭代矩阵:  $B_{GS} = (D - L)^{-1}U$ 。
- 收敛性: 若  $A$  为 **SPD** 矩阵, GS 法必收敛。

### (3) 超松弛迭代 (SOR 法)

- 思想: 对 GS 迭代进行加权平均 (外推), 加速收敛。

$$x^{(k+1)} = (1 - \omega)x^{(k)} + \omega x_{GS}^{(k+1)}$$

其中  $\omega$  为松弛因子。

- 分裂:  $M = \frac{1}{\omega}(D - \omega L)$ 。
- 迭代矩阵:

$$B_{SOR} = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]$$

- 收敛性:
  1. 必要条件:  $0 < \omega < 2$  (Kahan 定理)。
  2. 若  $A$  为 SPD, 则  $0 < \omega < 2 \iff$  SOR 收敛。

- **最优松弛因子**：对于具有 Property A 的矩阵（如三对角阵）：

$$\omega_{opt} = \frac{2}{1 + \sqrt{1 - \rho(B_J)^2}}$$

此时  $\rho(B_{SOR}) = \omega_{opt} - 1$ 。

## (三) 非定常迭代法 (Krylov Subspace Methods)

### 1. 变分原理与 Ritz 方法基础

#### (1) 算子方程与变分问题的等价性

考虑线性方程组  $Ax = b$ ，其中  $A \in \mathbb{R}^{n \times n}$  是 \*\* 对称正定 (SPD) \*\* 矩阵。

**定理** (变分原理). 求解  $Ax = b$  等价于寻找二次泛函  $\phi(x)$  的极小值点：

$$\phi(x) = \frac{1}{2}(Ax, x) - (b, x) = \frac{1}{2}x^T Ax - b^T x$$

即  $x^* = A^{-1}b \iff x^* = \arg \min_{x \in \mathbb{R}^n} \phi(x)$ 。

证明. 计算  $\phi(x)$  的梯度：

$$\nabla \phi(x) = \frac{1}{2}(A + A^T)x - b = Ax - b \quad (\text{因 } A = A^T)$$

令梯度为零，即  $Ax - b = 0 \implies Ax = b$ 。由于  $A$  正定，Hessian 矩阵  $\nabla^2 \phi(x) = A$  正定，故驻点为严格极小值点。  $\square$

#### (2) Ritz 方法与子空间逼近

- **基本思想**：在全空间  $\mathbb{R}^n$  中求极值可能太慢。Ritz 方法试图在一系列逐渐扩大的低维子空间  $V_k$  中寻找  $\phi(x)$  的近似极小点。
- **Ritz 问题**：设  $V_k = \text{span}\{p_0, p_1, \dots, p_{k-1}\}$ 。寻找  $x_k \in x_0 + V_k$  使得

$$\phi(x_k) = \min_{x \in x_0 + V_k} \phi(x)$$

- **几何解释**： $x_k$  是精确解  $x^*$  在子空间  $x_0 + V_k$  上的 \*\*A-正交投影\*\*。
- 即误差  $e_k = x_k - x^*$  满足  $e_k \perp_A V_k$  ( $e_k^T A v = 0, \forall v \in V_k$ )。

### (3) 梯度与下降方向

- **残差与梯度**:  $r(x) = b - Ax = -\nabla\phi(x)$ 。残差即负梯度方向。
- **最速下降方向**:  $p_k = r_k$ 。这是局部下降最快的方向，但在椭圆狭长山谷中会导致“锯齿形”振荡，收敛极慢。
- **A-共轭方向**: 为克服锯齿效应，我们希望搜索方向  $p_0, p_1, \dots$  能够使得每一步的搜索互不干扰。这就引入了 \*\*A-正交（共轭）\*\* 的概念：

$$(p_i, p_j)_A = p_i^T A p_j = 0, \quad i \neq j$$

在 A-共轭方向系下，二次型  $\phi(x)$  的等高线被“拉圆”了，从而可以快速收敛。

### (4) 一维搜索理论 (One-Dimensional Search)

在变分方法中，给定当前点  $x_k$  和下降方向  $p_k$ ，我们需要确定一个步长  $\alpha_k$ ，使得目标函数在沿该方向上达到极小。

$$x_{k+1} = x_k + \alpha_k p_k$$

- **一维搜索问题**: 寻找  $\alpha_k$  使得  $f(\alpha) = \phi(x_k + \alpha p_k)$  最小。
- **最优步长推导**: 将  $f(\alpha)$  对  $\alpha$  求导并令其为 0:

$$f'(\alpha) = \frac{d}{d\alpha} \phi(x_k + \alpha p_k) = (\nabla\phi(x_k + \alpha p_k), p_k)$$

代入  $\nabla\phi(x) = Ax - b = -r(x)$ ，得：

$$-(r(x_k + \alpha p_k), p_k) = 0$$

利用残差的线性性质  $r(x_k + \alpha p_k) = b - A(x_k + \alpha p_k) = (b - Ax_k) - \alpha A p_k = r_k - \alpha A p_k$ :

$$(r_k - \alpha A p_k, p_k) = 0 \implies (r_k, p_k) - \alpha (A p_k, p_k) = 0$$

解得最优步长：

$$\alpha_k = \frac{(r_k, p_k)}{(A p_k, p_k)}$$

- **结论**: 无论是在最速下降法还是共轭梯度法中，每一步的步长  $\alpha_k$  都是由上述公式确定的，它保证了新残差  $r_{k+1}$  与当前搜索方向  $p_k$  正交。

### (5) 单调性与收敛性分析

**命题**: 在给定下降方向  $p_k$  (满足  $p_k^T r_k > 0$ ) 并采用最优步长  $\alpha_k$  后，目标函数  $\phi(x)$ 、残差范数（在特定条件下）及误差范数（在特定度量下）均呈现单调下降趋势。

证明. 1. 目标函数值下降 ( $\phi(x_{k+1}) < \phi(x_k)$ ): 将  $x_{k+1} = x_k + \alpha_k p_k$  代入二次泛函展开:

$$\phi(x_{k+1}) = \phi(x_k) + \alpha_k (Ax_k - b, p_k) + \frac{1}{2} \alpha_k^2 (Ap_k, p_k)$$

由于  $Ax_k - b = -r_k$ , 所以  $(Ax_k - b, p_k) = -(r_k, p_k)$ 。代入最优步长  $\alpha_k = \frac{(r_k, p_k)}{(Ap_k, p_k)}$ :

$$\begin{aligned} \phi(x_{k+1}) &= \phi(x_k) - \frac{(r_k, p_k)^2}{(Ap_k, p_k)} + \frac{1}{2} \left( \frac{(r_k, p_k)}{(Ap_k, p_k)} \right)^2 (Ap_k, p_k) \\ &= \phi(x_k) - \frac{(r_k, p_k)^2}{2(Ap_k, p_k)} \end{aligned}$$

因为  $A$  正定,  $(Ap_k, p_k) > 0$ , 且  $(r_k, p_k) \neq 0$  (否则已收敛), 故减项恒正。

$$\therefore \phi(x_{k+1}) < \phi(x_k)$$

这证明了变分函数值是严格单调下降的。

2. 误差的  $A$ -范数下降: 定义误差  $e_k = x^* - x_k$ 。注意这里  $\phi(x)$  与误差的  $A$ -范数有直接关系:

$$\phi(x) = \frac{1}{2} (A(x^* - e), x^* - e) - (b, x^* - e) = \phi(x^*) + \frac{1}{2} (Ae, e) = \phi(x^*) + \frac{1}{2} \|e\|_A^2$$

由于  $\phi(x^*) = \text{const}$  且  $\phi(x_{k+1}) < \phi(x_k)$ , 直接推出:

$$\|e_{k+1}\|_A < \|e_k\|_A$$

即误差在  $A$ -范数意义下是单调递减的。

3. 残差的正交性: 由一维搜索条件  $f'(\alpha_k) = 0$  可知:

$$(r_{k+1}, p_k) = 0$$

这意味着新残差与当前的搜索方向正交。在几何上, 这是在此方向上能达到的“最低点”的特征。  $\square$

## 2. 最速下降法 (Steepest Descent)

### (1) 算法流程与性质

- 下降方向: 取负梯度方向  $p_k = r_k = b - Ax_k$ 。
- 最优步长:  $\alpha_k = \frac{(r_k, r_k)}{(Ar_k, r_k)}$ 。
- 迭代公式:

$$x_{k+1} = x_k + \alpha_k r_k$$

- 残差递推公式:

$$r_{k+1} = r_k - \alpha_k Ar_k$$

这避免了每次迭代计算  $b - Ax_{k+1}$  的矩阵向量乘法。

**定理** (相邻残差正交性). 在最速下降法中, 相邻两步的残差相互正交, 即  $(r_{k+1}, r_k) = 0$ 。

**证明.** 由最优步长条件 (一维搜索性质) 可知  $(r_{k+1}, p_k) = 0$ 。而在最速下降法中,  $p_k = r_k$ 。故  $(r_{k+1}, r_k) = 0$ 。□

**备注** (锯齿现象). 由于  $r_{k+1} \perp r_k$ , 意味着搜索方向在每一步都必须拐 90 度弯。在等高线为狭长椭圆 (条件数  $\kappa$  很大) 的情况下, 这会导致算法在 “山谷” 底部反复震荡, 前进极慢, 形成锯齿形路径。

## (2) 收敛性定理与证明 (Kantorovich 不等式)

**定理** (最速下降法收敛速度). 设  $A$  是 SPD 矩阵, 特征值为  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n > 0$ 。则最速下降法的误差满足:

$$\|e_{k+1}\|_A \leq \frac{\kappa - 1}{\kappa + 1} \|e_k\|_A$$

其中  $\kappa = \text{cond}_2(A) = \frac{\lambda_1}{\lambda_n} = \frac{\lambda_{\max}}{\lambda_{\min}}$ 。

**说明.** 证明思路 1. **误差递推关系:** 由  $x_{k+1} = x_k + \alpha_k r_k$ , 两边减  $x^*$  得  $e_{k+1} = e_k - \alpha_k r_k$ 。注意  $r_k = b - Ax_k = A(x^* - x_k) = Ae_k$ , 代入得:

$$e_{k+1} = e_k - \alpha_k Ae_k = (I - \alpha_k A)e_k$$

2. **能量范数递推:** 计算  $\|e_{k+1}\|_A^2 = (Ae_{k+1}, e_{k+1})$ :

$$\|e_{k+1}\|_A^2 = (A(e_k - \alpha_k r_k), e_k - \alpha_k r_k)$$

展开并代入最优步长  $\alpha_k = \frac{(r_k, r_k)}{(Ar_k, r_k)}$  (推导略繁琐, 直接利用函数值下降公式): 我们已知  $\phi(x_{k+1}) = \phi(x_k) - \frac{(r_k, r_k)^2}{2(Ar_k, r_k)}$ 。利用  $\phi(x) = \phi(x^*) + \frac{1}{2}\|e\|_A^2$ , 得:

$$\frac{1}{2}\|e_{k+1}\|_A^2 = \frac{1}{2}\|e_k\|_A^2 - \frac{(r_k, r_k)^2}{2(Ar_k, r_k)}$$

于是:

$$\frac{\|e_{k+1}\|_A^2}{\|e_k\|_A^2} = 1 - \frac{(r_k, r_k)^2}{(Ar_k, r_k) \cdot \|e_k\|_A^2}$$

注意  $\|e_k\|_A^2 = (Ae_k, e_k) = (r_k, A^{-1}r_k)$ , 代入上式:

$$\frac{\|e_{k+1}\|_A^2}{\|e_k\|_A^2} = 1 - \frac{(r_k, r_k)^2}{(Ar_k, r_k)(A^{-1}r_k, r_k)}$$

3. **利用 Kantorovich 不等式:** 对于 SPD 矩阵  $A$ , Kantorovich 不等式指出:

$$\frac{(x, x)^2}{(Ax, x)(A^{-1}x, x)} \geq \frac{4\lambda_1\lambda_n}{(\lambda_1 + \lambda_n)^2}$$

将  $x$  替换为  $r_k$ , 代入递推式:

$$\frac{\|e_{k+1}\|_A^2}{\|e_k\|_A^2} \leq 1 - \frac{4\lambda_1\lambda_n}{(\lambda_1 + \lambda_n)^2} = \left(\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n}\right)^2 = \left(\frac{\kappa - 1}{\kappa + 1}\right)^2$$

开方即得证。



### 3. 共轭梯度法 (Conjugate Gradient, CG)

#### (1) 基本思想

- **共轭方向**: 寻找一组关于  $A$  正交 (共轭) 的方向  $\{p_0, p_1, \dots\}$ , 即  $p_i^T A p_j = 0$  ( $i \neq j$ )。
- **最优性**: 第  $k$  步得到的解  $x_k$  使得  $\phi(x)$  在 Krylov 子空间  $\mathcal{K}_k(A, r_0) = \text{span}\{r_0, Ar_0, \dots, A^{k-1}r_0\}$  上达到极小。

#### (2) CG 算法流程

初始化  $x_0$ , 计算  $r_0 = b - Ax_0$ , 令  $p_0 = r_0$ 。对于  $k = 0, 1, \dots$ :

1.  $\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}$  (计算步长)
2.  $x_{k+1} = x_k + \alpha_k p_k$  (更新解)
3.  $r_{k+1} = r_k - \alpha_k A p_k$  (更新残差)
4.  $\beta_k = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}$  (计算方向更新系数)
5.  $p_{k+1} = r_{k+1} + \beta_k p_k$  (更新搜索方向)

#### (3) 收敛性分析

- **有限步终止**: 理论上至多  $n$  步收敛到精确解 (无舍入误差时)。
- **误差估计**:

$$\frac{\|e_k\|_A}{\|e_0\|_A} \leq 2 \left( \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k$$

收敛速度远快于最速下降法, 且依赖于  $\sqrt{\text{cond}(A)}$ 。

### 4. 预处理技术 (Preconditioning)

- **目的**: 改善矩阵条件数, 加速 CG 收敛。
- **方法**: 求解等价方程  $M^{-1}Ax = M^{-1}b$ , 其中  $M \approx A$  且  $M$  易求逆。
- **预优 CG (PCG)**: 在 CG 算法中引入  $M^{-1}$ , 实际上是在  $M$ -内积下进行正交化。
- **常用预条件子**: Jacobi (对角 Scaling), Incomplete Cholesky (IC)。

**待填写: ()** 从 *PPT* 和作业来看, 预处理 *CG* 的细节不是考试重点, 大概考不了... 艰深而收获小, 摆了, 建议大家多花点精力复习别的章节 (